Classificação de tipos de fratura em radiografias com transfer learning

Deep Learning Aplicado 2026/2027 · P1-D2 · Mariana Mendonça · Samira Cunha · Turma TP1

1. Problema e dados

Classificação de radiografias em **10 tipos de fratura** com o dataset *Bone Break Classification* (Kaggle, CC BY 4.0). O ZIP original tinha 1 129 imagens em pastas `Train`/`Test`; a auditoria encontrou radiografias quase iguais entre essas pastas e grupos semelhantes com rótulos diferentes, pelo que excluímos 14 imagens de 6 grupos com rótulos conflitantes e removemos 70 cópias excedentes, ficando **1 045 imagens**. As classes estão moderadamente desequilibradas: de 6,8% (Longitudinal, 71) a 14,1% (Fracture Dislocation, 147). A resolução é variável (largura mediana 283–640 px).

Fizemos uma nova divisão **estratificada 70/15/15 (seed 42): 731 treino / 157 validação / 157 teste**, guardada em `splits.csv` e reutilizada em todas as aulas. O notebook verifica 0 ficheiros em falta, 0 rótulos divergentes e **0 interseções de SHA-256** entre conjuntos. Não existe identificador de doente ou sessão, pelo que **não foi possível dividir por grupo**; a ausência de duplicados exatos não exclui imagens quase duplicadas ou do mesmo doente.

2. Modelos

- **Baseline de raiz (aula 2):** 4 blocos Conv+MaxPool (32→256 filtros), GlobalAveragePooling e Dense softmax; entrada 180×180 com `Rescaling(1/255)`; Adam 1e-3; 390 986 parâmetros.
- **Extração de características:** EfficientNetB0 (ImageNet) **congelada**, chamada com `training=False`; cabeça GAP + Dropout 0,3 + Dense(10); entrada 224×224 com píxeis 0–255 (pré-processamento incluído no modelo, sem `Rescaling`); Adam 1e-3. *Data augmentation* (flip horizontal, rotação 0,1, zoom 0,2) dentro do modelo — só ativa em treino.
- **Fine-tuning:** a partir do melhor extrator, descongelámos as últimas 20 camadas da base, mantendo as BatchNormalization congeladas (15 camadas treináveis) e treinámos com **learning rate 100× menor (1e-5)**.
-

Todos usaram batch 32, seed 42, `EarlyStopping(val_loss, patience=5, restore_best_weights)`, `ModelCheckpoint` pela menor `val_loss` e TensorBoard (máx. 30/30/20 épocas). A EfficientNetB0 foi preferida à ResNet50 (23,6 M parâmetros) e à ConvNeXtTiny (27,8 M) por ser a mais pequena (4,0 M) para um dataset de 731 imagens de treino (verificado com `count_params()`).

3. Resultados

Comparação na validação (Tabela 1, Figura 1). O classificador maioritário obtém 14,0%; o transfer learning quase duplica a accuracy da baseline com 30× menos parâmetros treináveis. O fine-tuning **não baixou a val_loss**: a melhor época foi a primeira e o treino parou na 6.ª. A sua accuracy e F1 ligeiramente superiores (+0,6 p.p. = 1 imagem) estão dentro do ruído. Pelo critério definido antes de olhar para o teste (menor `val_loss`), **o modelo final é o extrator de características**.

Modelo	Parâm. treináveis	Melhor época	Menor val_loss	Acc. val.	F1 macro val.	Tempo (min)
CNN baseline (de raiz, 180×180)	390 986	18 / 23	2,175	21,0%	0,141	1,3
EfficientNetB0 — extração de características	12 810	25 / 30	**1,917**	38,2%	0,334	2,3
EfficientNetB0 — fine-tuning (+20 camadas)	1 355 578	1 / 6	1,920	38,9%	0,340	0,6

Tabela 1 — Comparação na validação (melhor época pela menor val_loss / épocas executadas).

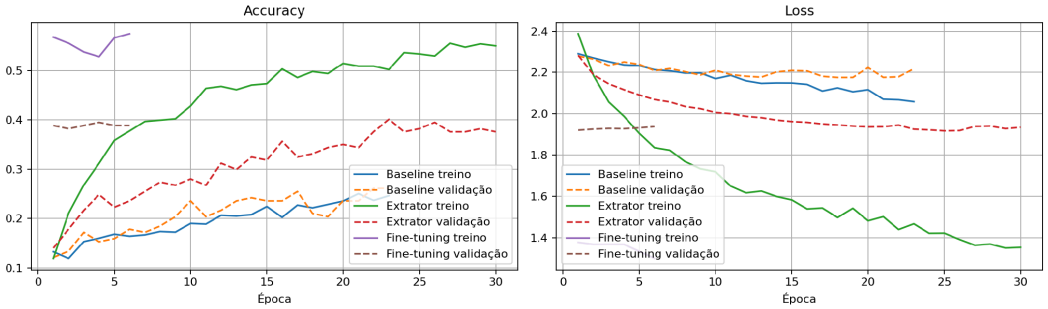


Figura 1 — Curvas de treino e validação. A baseline estagna perto de 21%; o extrator melhora até à época 25; o fine-tuning não altera a val_loss.

Avaliação única no teste do modelo selecionado: **accuracy 42,7%**, **F1 macro 0,369**, **AUC macro OvR 0,785**. Usamos o F1 macro como métrica principal porque dá o mesmo peso às classes pequenas. A accuracy global esconde classes falhadas: **Longitudinal tem recall 0/11** (a única previsão desta classe foi um Hairline) e **Oblique tem 1/12**, confundida com Greenstick e Fracture Dislocation. Hairline é prevista mais vezes como Pathological (5/17) do que corretamente (4/17). Pathological, Spiral e Greenstick acumulam falsos positivos (14, 11 e 9).

Classe (n teste)	Prec.	Recall	F1	AUC
Avulsion (18)	0,41	0,50	0,45	0,84
Comminuted (20)	0,47	0,35	0,40	0,60
Fracture Dislocation (22)	0,42	0,50	0,46	0,81
Greenstick (17)	0,57	0,71	**0,63**	**0,95**
Hairline (17)	0,33	0,24	0,28	0,81
Impacted (11)	0,25	0,27	0,26	0,77
Longitudinal (11)	0,00	**0,00**	**0,00**	0,72
Oblique (12)	0,33	**0,08**	0,13	0,66
Pathological (18)	0,46	0,67	0,55	0,84
Spiral (11)	0,42	0,73	0,53	0,86
Macro	**0,37**	**0,40**	**0,37**	**0,79**

Tabela 2 — Relatório por classe e AUC one-vs-rest no teste (157 imagens).

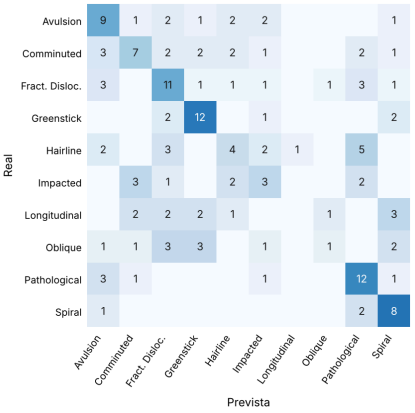


Figura 2 — Matriz de confusão no teste (cor = % da linha).

Threshold escolhido. A decisão multiclasse usa `argmax`. Como exemplo de decisão binária com custo assimétrico, estudámos **Pathological fracture vs. resto**: uma fratura patológica sinaliza doença óssea subjacente, pelo que falhá-la é mais grave do que gerar um alarme falso. O threshold foi escolhido **na validação**: **0,2** maximiza o índice de Youden (0,532) e recupera 68% dos casos, contra 32% com 0,5. Em rastreio puro, 0,1 daria recall de 79% com FPR de 27%. No teste, 0,2 mantém o comportamento (TPR 0,667; FPR 0,151). (Exercício manual: AUC 0,84, confirmada com `roc_auc_score`; Youden máximo em 0,6; 0,3 para rastreio.)

Pathological vs. resto	TP	FP	FN	TN	TPR (recall)	FPR	Precision	TPR − FPR
Validação, th = 0,1	15	37	4	101	0,789	0,268	0,288	0,521
Validação, th = 0,2 (escolhido)	13	21	6	117	0,684	0,152	0,382	**0,532**
Validação, th = 0,5	6	10	13	128	0,316	0,072	0,375	0,243
Teste, th = 0,2	12	21	6	118	0,667	0,151	0,364	0,516

Tabela 3 — Escolha do threshold para Pathological (one-vs-rest).

4. Interpretação (Grad-CAM)

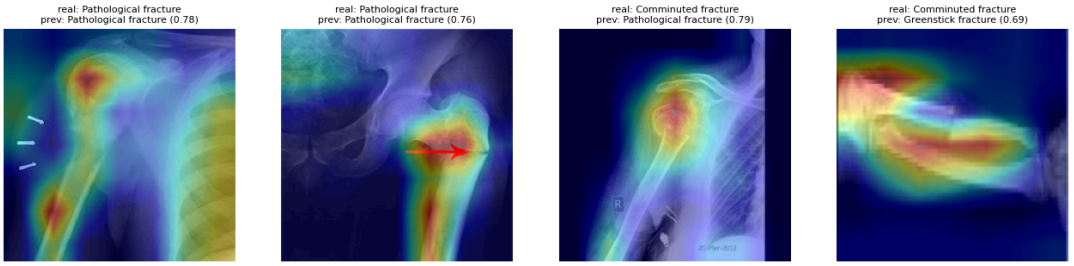


Figura 3 — Grad-CAM (última camada da EfficientNetB0) para os 2 acertos e os 2 erros com maior confiança.

Imagem	Real	Prevista (prob.)	Onde se foca o mapa?	Foco plausível? Porquê?
#142 (acerto)	Pathological	Pathological (0,78)	Cabeça do úmero e diáfise proximal	**Sim** — coincide com a lesão; as setas anotadas à esquerda não são ativadas.
#145 (acerto)	Pathological	Pathological (0,76)	Colo do fêmur, exatamente na ponta da seta vermelha	**Duvidoso** — é a região da lesão, mas também a da seta: não é possível separar lesão de anotação.
#23 (erro)	Comminuted	Pathological (0,79)	Cabeça do úmero (local da fratura)	**Parcial** — região correta, mas o padrão de fragmentos não é distinguido; imagem com marca «R» e data.
#36 (erro)	Comminuted	Greenstick (0,69)	Difuso ao longo da diáfise	**Não** — sem foco no traço de fratura; a imagem está muito ampliada e distorcida pelo redimensionamento.

Nos erros adicionais analisados, o mapa ativa sobre texto e marcas: a etiqueta «Left» no erro #35 (Comminuted → Pathological) e a marca d'água no fundo do #127 (Oblique → Spiral). No #17 (Avulsion → Hairline), o foco está nas falanges e não no local da avulsão. **Hipóteses para os erros:** (i) **atalhos** em setas, letras e marcas de água; (ii) **ruído de rótulo**, já evidenciado pelos conflitos encontrados; (iii) **perda de detalhe** ao redimensionar para 224×224 sem manter a proporção, quando as classes diferem pela geometria fina do traço (longitudinal vs. oblíqua vs. espiral); (iv) **poucos exemplos** nas classes falhadas (49–56 imagens de treino). A testar na validação: *central crop*/mascaramento das margens, *class weights* e maior resolução.

5. Uso de IA

Assistentes de IA (incluindo o Gemini) ajudaram a estruturar o notebook e as verificações de fuga, a adaptar o Grad-CAM e a interpretar a matriz de confusão. Tiveram de ser corrigidos: a IA propôs usar a divisão `Train`/`Test` do ZIP, que tinha quase duplicados; afirmou que Longitudinal «nunca é prevista» (há 1 previsão); recomendou thresholds de rejeição de 0,5/0,6 sem os avaliar; e disse que o fine-tuning era «indispensável», quando este não melhorou a val_loss. Todos os números deste relatório foram confirmados contra os outputs do notebook (detalhe em `AI_LOG.md`).

Limitações: o conjunto de teste foi consultado uma vez numa experiência exploratória do Protocolo 1 (CNN e MobileNetV2), antes da seleção atual; desde então não guiou nenhuma decisão. Usámos uma única seed. O teste tem 11–22 imagens por classe, pelo que as métricas por classe têm grande incerteza. Os resultados não demonstram adequação clínica.